Artificial Intelligence Project Report

Image Segmentation

Dr.Sajedi

Author: Morteza Rashidkhan

1. Preprocessing:

در ابتدا ما عکس ها و mask ها را از فایل می خوانیم و آن ها را resize می کنیم به عکس های با سایز 256*256 و همچنین آن ها را normalize میکنیم و آن ها را برای training آماده می کنیم.

```
class TfdataPipeline:

      …

      …

      def __read_image_and_mask(self, image_path: str, mask_path: str) -
>                                                                  tf.Tensor:

        img_raw              =              tf.io.read_file(image_path)
        mask_raw              =              tf.io.read_file(mask_path)

        img                  =                tf.io.decode_jpeg(img_raw)
        mask       =       tf.io.decode_jpeg(mask_raw,       channels=1)

        img = tf.image.convert_image_dtype(img, tf.float32) # normalize
the                  values                  between                  0-1

        mask    =    tf.image.convert_image_dtype(mask,    tf.float32)    #
normalize           the           values           between           0-1

        img    =    tf.image.resize(img,    [self.IMG_H,    self.IMG_W])
        mask    =    tf.image.resize(mask,    [self.IMG_H,    self.IMG_W])

        return img, mask
```

2. Model Selection and Implementation:

2.1.Selected model: PraNet (Parallel Reverse Attention Network)

این مدل که در مقاله نیز به آن اشاره شده 3 تا مولفه اصلی دارد که به شرح زیر است:

- Feature Extractor Backbone
- Parallel Partial Decoder Block
- Reverse Attention Block (Reverse Attention for Salient object detection)

Feature Extractor Backbone:

یک Feature Extractor Backbone می‌تواند هر مدل شناخت تصویر با کارایی بالا باشد. برای خروجی با دقت بالا از resnet50 که روی داده های Imagenet از قبل train شده است. هدف نهایی استفاده از یک

Feature Extractor Backbone پیش‌آموزش دیده، استخراج ویژگی‌های سطح بالا از تصاویر و جمع‌آوری این ویژگی‌ها به منظور به‌دست آوردن یک نقشه سراسری است.

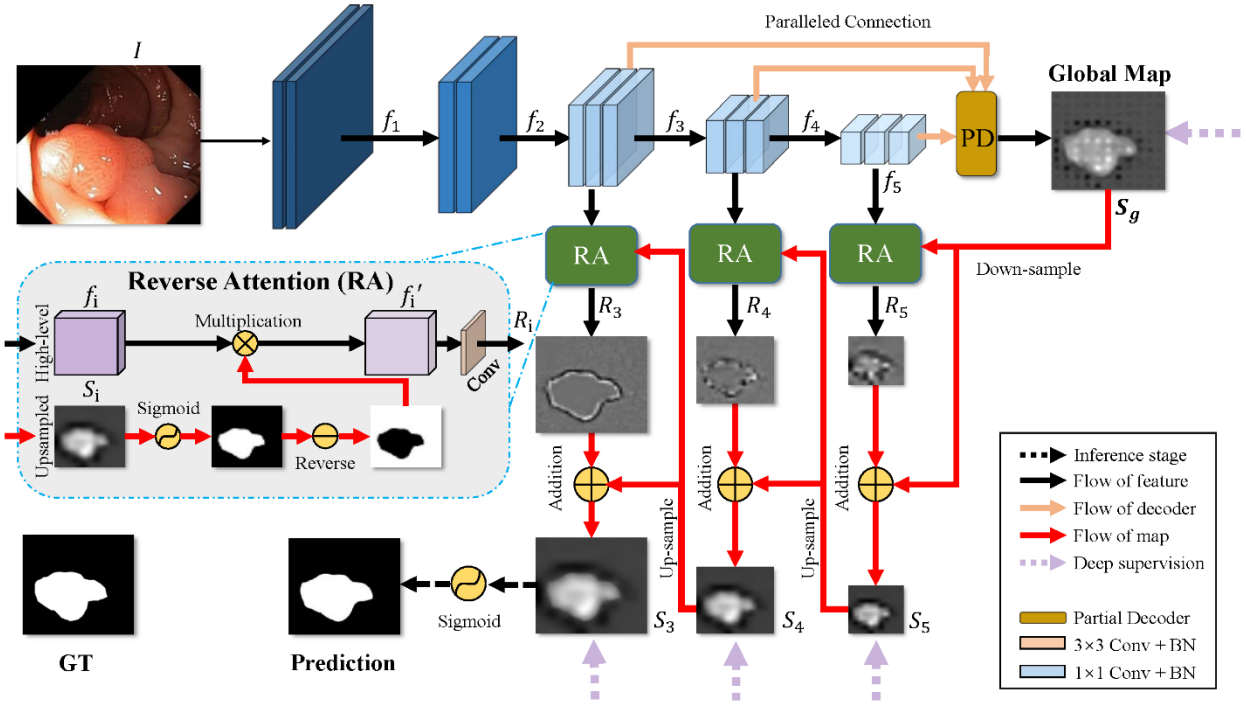

PraNet Architecture

Parallel Partial Decoder:

بیشتر مدل‌های تقسیم تصویر پزشکی محبوب مانند Unet، U-net++، ResUnet و غیره، مدل‌های کامل کدگشا هستند یعنی تمام ویژگی‌های چند سطحی از شبکه اصلی را جمع‌آوری می‌کنند. اما در مقایسه با ویژگی‌های سطح بالای اسکلت، ویژگی‌های سطح پایین به دلیل داشتن وضوح فضای بزرگتر، نیازمند منابع محاسباتی بیشتری هستند، اما کمتر به عملکرد کلی مدل ارتباط دارند. بنابراین، این مدل از یک بلوک PPD (Parallel Partial Decoder) استفاده می کند که تنها ویژگی‌های سطح بالا که از مدل پیش‌آموزش دیده resnet50 استخراج شده‌اند را جمع‌آوری می‌کند تا یک نقشه جهت سراسری (Global Saliency Map) به‌دست آید. این بلوک تمام ویژگی‌های سطح بالا را به صورت موازی جمع می‌کند و اینطوری مدل سریعتر و کارآمدتر می‌شود.

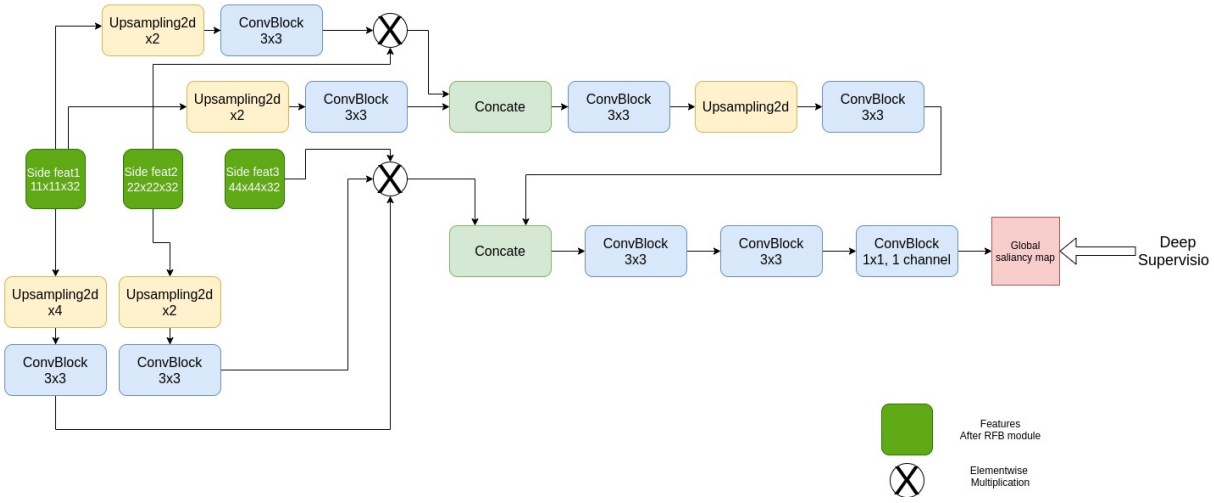

PPD block

Reverse Attention:

در یک محیط بالینی، پزشکان ابتدا به طور تقریبی ناحیه پولیپ را تعیین می کنند و سپس بافت های محلی را به دقت بررسی می کنند تا به طور دقیق پولیپ را برچسب گذاری کنند. نقشه جهت سراسری ما از عمیق ترین لایه CNN مشتق شده است، که فقط می تواند یک مکان نسبتا ناهموار از بافت های پولیپ را بدون جزئیات ساختاری ثبت کند (شکل معماری پیشنهادی را ببینید). در این مدل یک استراتژی اصلی برای استخراج تدریجی نواحی پولیپ که متمایز از روش پاک کردن شی پیش زمینه همانطور که در مقاله Reverse Attention برای تشخیص شی برجسته ارائه شده است، استفاده می شود. در اینجا به جای تجمیع ویژگی‌ها از همه سطوح مانند U-net، ResUnet و Unet++ یادگیری تطبیقی Reverse Attention را در سه ویژگی سطح بالا موازی پیشنهاد می‌کند. به عبارت دیگر، معماری ما می تواند به طور متوالی مناطق و جزئیات مکمل را با پاک کردن مناطق پولیپ تخمین زده شده از ویژگی های خروجی جانبی سطح بالا استخراج کند، جایی که تخمین موجود از لایه عمیق تر نمونه برداری می شود.

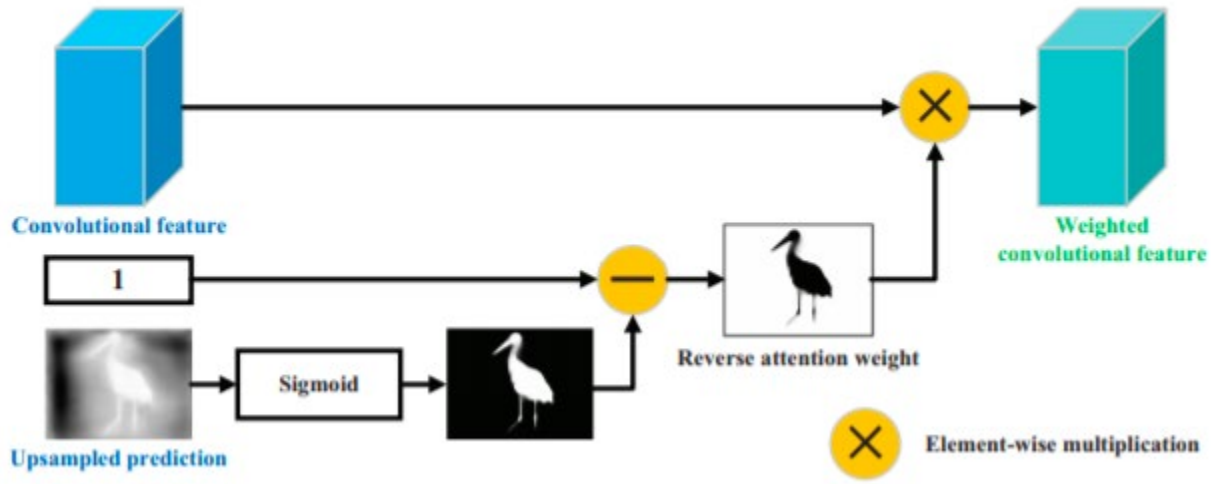

Reverse Attention block

2.2.Implementation:

```
class PRAnet(tf.keras.Model):
    def __init__(self, IMG_H: int = 352, IMG_W: int = 352, filters: int
= 32, backbone_arch:str = 'resnet50', backbone_trainable: bool = True,
**kwargs):
        super(PRAnet, self).__init__(**kwargs)
        self.IMG_H = IMG_H
        self.IMG_W = IMG_W
        self.filters = filters
        self.backbone_arc = backbone_arch
        self.backbone_trainable = backbone_trainable

        # pretrained resnet
        self.fe_backbone =
FE_backbone(model_architecture=self.backbone_arc,inshape=(self.IMG_H,
self.IMG_W, 3), is_trainable=self.backbone_trainable )
        self.backbone_feature_extractor =
self.fe_backbone.get_fe_backbone()

        # Receptive field blocks
        # 3 blocks for three high level features from resnet
        self.rfb_2 = RFB(filters=self.filters, name="rfb_2")
        self.rfb_3 = RFB(filters=self.filters, name="rfb_3")
        self.rfb_4 = RFB(filters=self.filters, name="rfb_4")

        # Paraller Partial Decoder Block
        self.ppd = PartialDecoder(filters=self.filters,
name="partial_decoder")
        self.resize_sg = preprocessing.Resizing(self.IMG_H, self.IMG_W,
```

```
name='salient_out_5')

        #          reverse          attention          branch          4
        self.resize_4      =      preprocessing.Resizing(self.IMG_H//32,
self.IMG_W//32,                                          name="resize4")
        self.ra_4                    =                   ReverseAttention(
            filters=256,       kernel_size=(5,       5),branch='gsmap',
name="reverse_attention_br4")
        self.resize_s4       =       preprocessing.Resizing(self.IMG_H,
self.IMG_W,name="salient_out_4")

        #          reverse          attention          branch          3
        self.resize_3      =      preprocessing.Resizing(self.IMG_H//16,
self.IMG_W//16,                                          name="resize3")
        self.ra_3             =            ReverseAttention(filters=64,
name="reverse_attention_br3")
        self.resize_s3 = preprocessing.Resizing(self.IMG_H, self.IMG_W,
name="salient_out_3")

        #          reverse          attention          branch          2
        self.resize_2      =      preprocessing.Resizing(self.IMG_H//8,
self.IMG_W//8,                                           name="resize2")
        self.ra_2             =            ReverseAttention(filters=64,
name="reverse_attention_br2")
        self.resize_s2 = preprocessing.Resizing(self.IMG_H, self.IMG_W,
name="final_salient_out_2")


    def call(self, x: tf.Tensor):

      …

      …

        return    lateral_out_sg,    lateral_out_s4,    lateral_out_s3,
lateral_out_s2


      …

      …
    def                                                get_config(self):
        …
    @classmethod
    def                    from_config(cls,                    config):
        return                                          cls(**config)

    def    build_graph(self,    inshape:tuple)    ->    tf.keras.Model:
        x             =            tf.keras.layers.Input(shape=inshape)
```

```
        return tf.keras.Model(inputs=[x], outputs = self.call(x),
name='PRAnet')
```

کد کامل داخل در مسیر model/PRA_net.py موجود است.

3. Training and Validation:

ما از 0.9 داده ها برای train و validation استفاده کردیم و 0.1 باقی مانده را برای prediction نگه داشتیم. برای trainکردن تعداد epoch ها را 25 انتخاب کردیم و همچنین تعداد batch ها 8 در نظر گرفتیم و learning rate را برای شروع 0.001 گذاشتیم. همچنین برای optimizer از Adam استفاده کردیم. تابع Loss که انتخاب کردیم در واقع مجموع Weighted BCE(Binary Cross Entropy loss) و Weighted Dice loss است.

loss = WBCE loss + WDice loss

کد مربوط به train این مدل در فایل PraNet_ARC_Final.ipynb قرار دارد.

در ادامه قسمتی از خروجی موقع training مشاهده می کنیم:

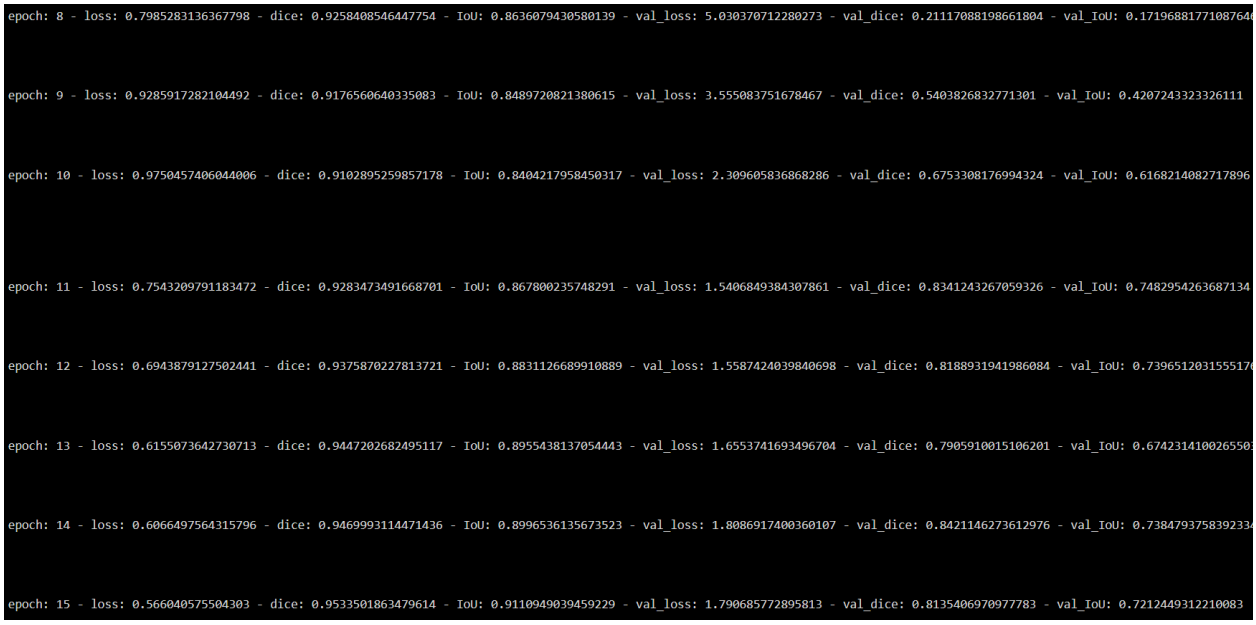

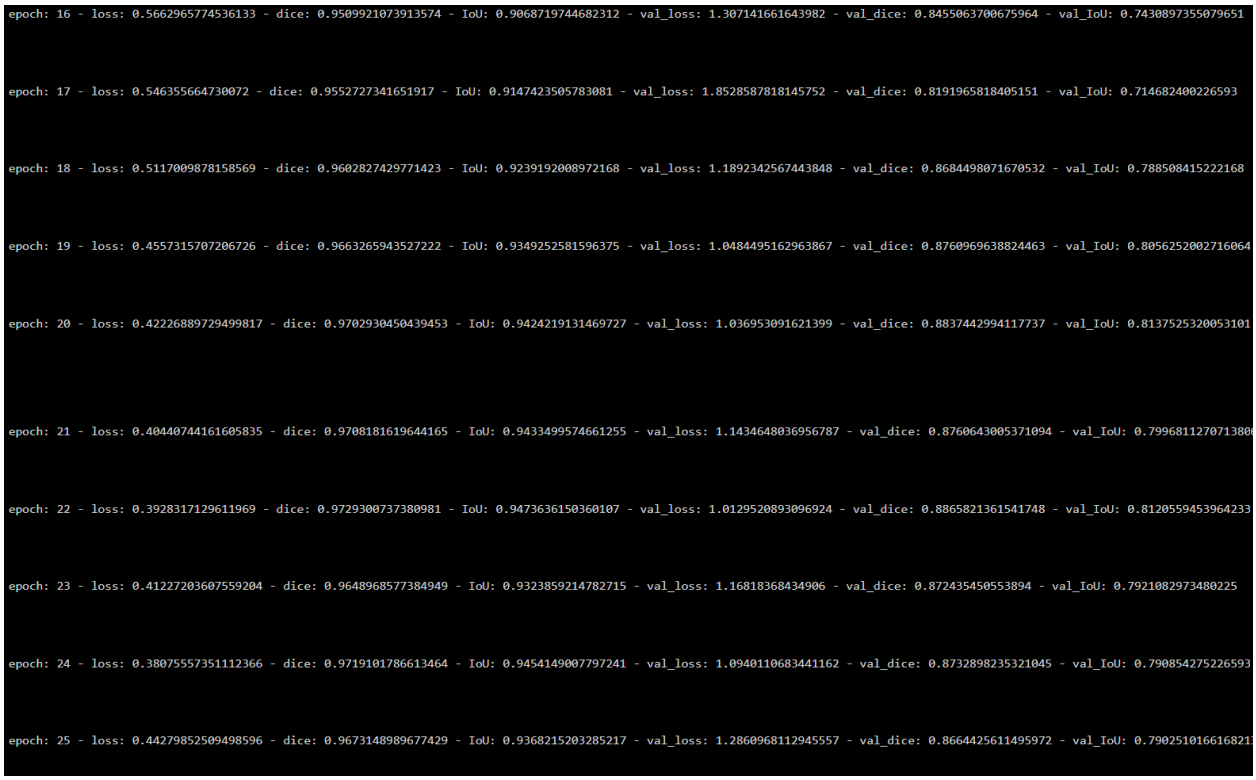

4. Results and Analysis:
   4.1.Performance

Architecture	Learning Rate	Epoch	Batch Size	DICE	IOU	MAE
PraNet_resnet50	1e-3	25	8	84.83	76.55	5.58
DPN68×2	1e-2	25	4	91.70	86.74	2.68

همانظور که از نتایج مشخص است مدلی که مقاله معرفی کرده یعنی DPN68×2 از نظر عملکرد کمی از مدل ما بهتر است.

در ادامه تعدادی از تصاویر که mask آنها توسط مدل train شده ما predict شده قرار داده شده است.

4.2.Results

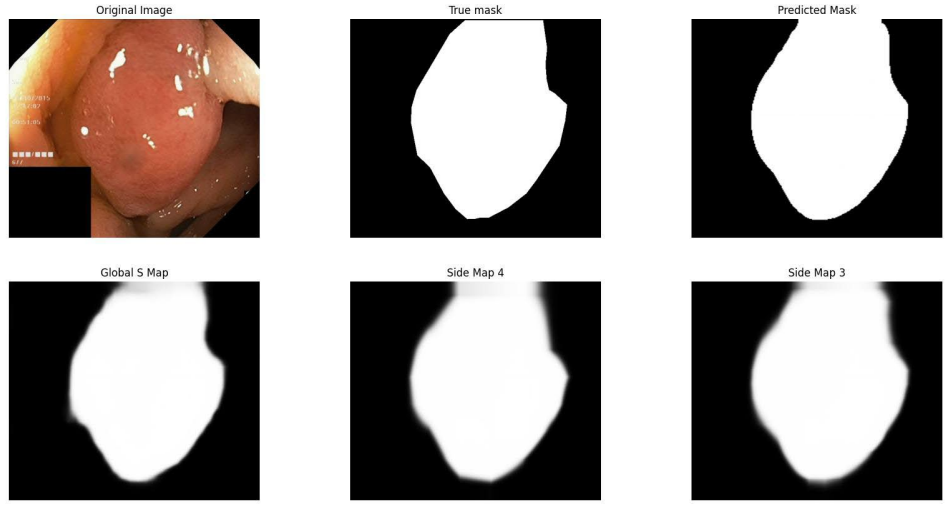
Original Image
True mask
Predicted Mask
Global S Map
Side Map 4
Side Map 3

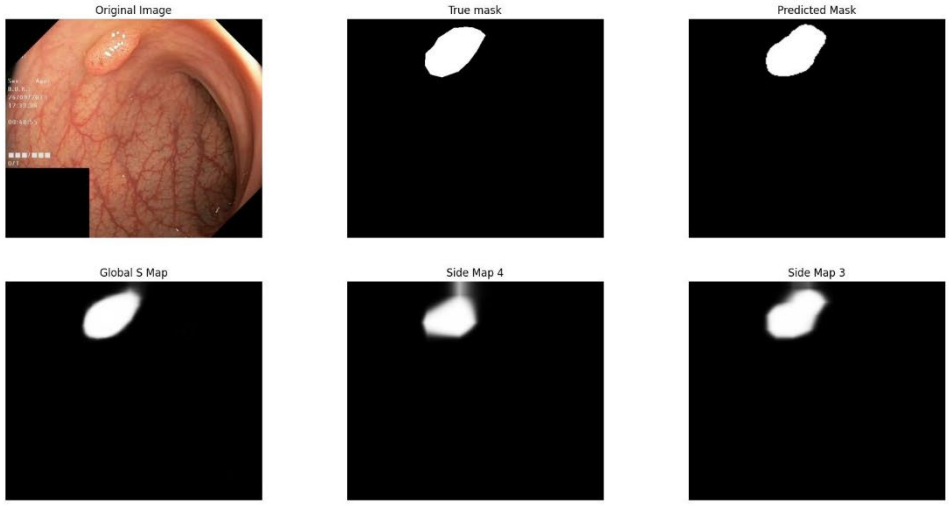
Original Image
True mask
Predicted Mask
Global S Map
Side Map 4
Side Map 3

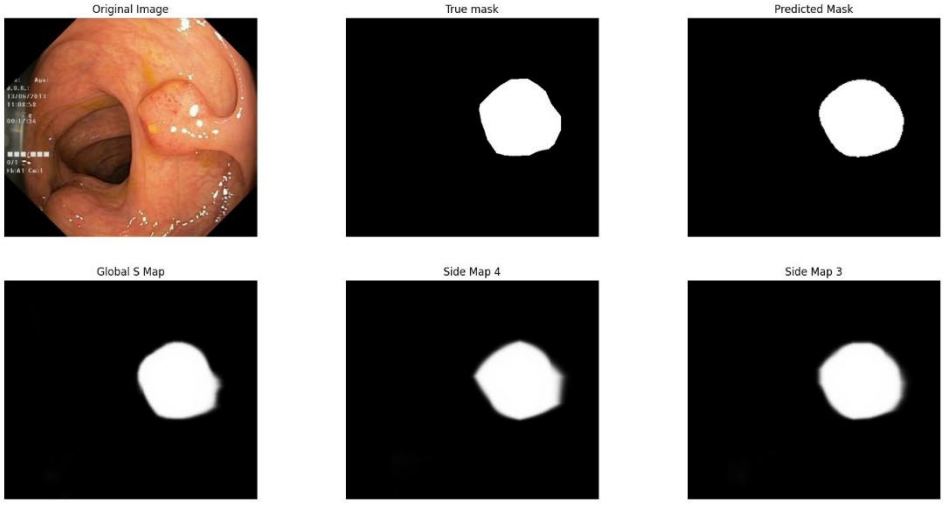
Original Image
True mask
Predicted Mask
Global S Map
Side Map 4
Side Map 3

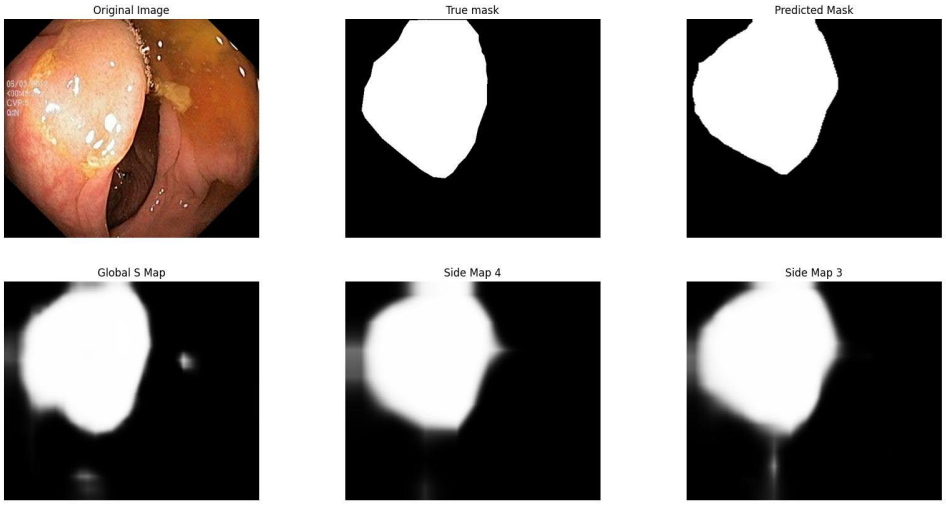
Original Image
True mask
Predicted Mask
Global S Map
Side Map 4
Side Map 3

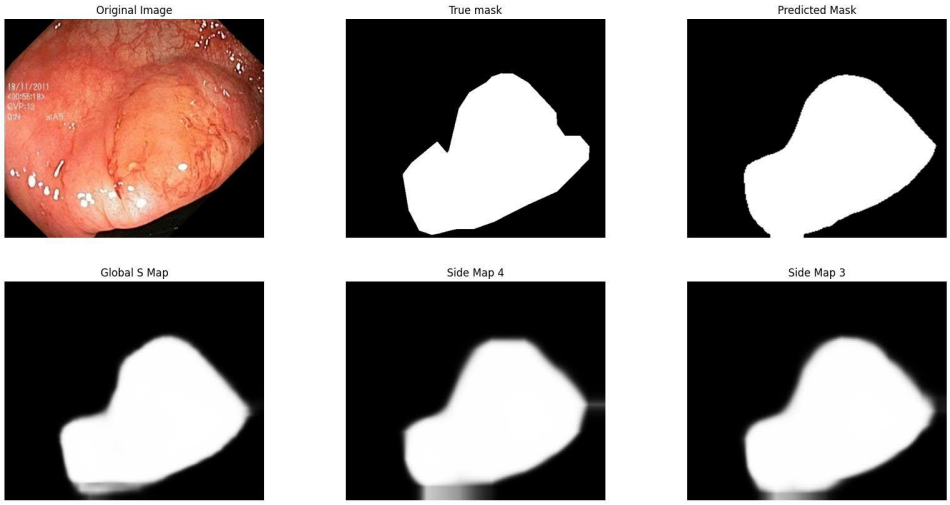

4.3.Challenges faced during training

ابتدا مدل ساده UNet را انتخاب کرده بودم (که کد آن در فایل UNET_ARC_Older.ipynb موجود است) ولی نتایج آن خیلی خوب نبود و مقدار IOU حدود 33.00 بود و اما مشکلی که موقع train کردن این مدل به آن برخوردم این بود که loss آن به سرعت منفی می شد و تا بی نهایت می رفت. پس از کلی تست کردن متوجه شدم که مشکل از normalize کردن mask ها در مرحله preprocessing بود که در واقع باید mask را تقسیم بر 255 می کردم تا همه مقادیر بین 0 و 1 قرار بگیرند و من اینکار را انجام نمی دادم.